Fatec
Baixada Santista
Rubens Lara

Principal Component Analysis – PCA

Aplicação em: "Causas de Mortes em países ao redor do mundo no ano de 1990"

2º Ciclo – Ciência de Dados
Álgebra Linear

Juliana Câmara Monteiro
RA 0051352211021

1. Dataset:

O dataset usado para a aplicação do PCA neste trabalho foi retirado do site Kaggle. Trata-se de uma base de dados com causas de mortes em países ao redor do mundo entre os anos de 1990 e 2019. Porém, a análise restringiu-se somente ao ano de 1990. O dataset é composto por 6120 linhas e 34 colunas, sendo que, a partir da quarta, encontram-se os registros de mortos por país (dados brutos). Segue relação de colunas:
1.1- Country/Territory
1.2- Code
1.3- Year
1.4- Meninitis
1.5- Alzheimer's Disease and Other Dementias
1.6- Parkinson's Disease
1.7- Nutritional Deficiencies
1.8- Malaria
1.9- Drowning
1.10- Interpersonal Violence
1.11- Maternal Disorders
1.12- HIV/AIDS
1.13- Drug Use Disorders
1.14- Tuberculosis
1.15- Cardiovascular Diseases
1.16- Lower Respiratory Infections
1.17- Neonatal Disorders
1.18- Alcohol Use Disorders
1.19- Self-harm
1.20- Exposure to Forces of Nature
1.21- Diarrheal Diseases
1.22- Environmental Heat and Cold Exposure
1.23- Neoplasms
1.24- Conflict and Terrorism
1.25- Diabetes Mellitus
1.26- Chronic Kidney Disease
1.27- Poisonings
1.28- Protein-Energy Malnutrition
1.29- Road Injuries
1.30- Chronic Respiratory Diseases
1.31- Cirrhosis and Other Chronic Liver Diseases
1.32- Digestive Diseases
1.33- Fire, Heat, and Hot Substances
1.34- Acute Hepatitis

Link: https://www.kaggle.com/datasets/iamsouravbanerjee/cause-of-deaths-around-the-world

2. Aplicando o PCA

A técnica foi aplicada através da linguagem Python, usando as bibliotecas Pandas, Numpy e Scikit-learn, seguindo as seguintes etapas:

Carregando o DataFrame - Causas de mortes em países ao redor do mundo dos anos de 1990 à 2019.

```
[1] import pandas as pd
    import numpy as np
```

```
causas_mortes = pd.read_csv('cause_of_deaths.csv')
causas_mortes = pd.DataFrame(causas_mortes)
print(causas_mortes)
```

Após atribuir os registros do arquivo CSV ao DataFrame, excluiremos os valores repetidos da coluna de classificação dos anos, mantendo assim, somente os dados dos anos de 1990 para cada país. Logo após, verificaremos os tipos de varáveis que compõem o dataset para identificar quais colunas participarão da matriz de correlação

Removendo valores duplicados da coluna de "Country/Territory". Serão contabilizados somente os registros dos anos de 1990 para cada país.

```
[ ] causas_mortes = causas_mortes.drop_duplicates(subset= 'Country/Territory')
    print(causas_mortes)
```

```
causas_mortes.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 6120 entries, 0 to 6119
Data columns (total 34 columns):
 #   Column                                  Non-Null Count  Dtype
```

Saída:

```
Data columns (total 34 columns):
 #   Column                                     Non-Null Count  Dtype
---  ------                                     --------------  -----
 0   Country/Territory                          6120 non-null   object
 1   Code                                       6120 non-null   object
 2   Year                                       6120 non-null   int64
 3   Meningitis                                 6120 non-null   int64
 4   Alzheimer's Disease and Other Dementias    6120 non-null   int64
 5   Parkinson's Disease                        6120 non-null   int64
 6   Nutritional Deficiencies                   6120 non-null   int64
 7   Malaria                                    6120 non-null   int64
 8   Drowning                                   6120 non-null   int64
 9   Interpersonal Violence                     6120 non-null   int64
 10  Maternal Disorders                         6120 non-null   int64
 11  HIV/AIDS                                   6120 non-null   int64
 12  Drug Use Disorders                         6120 non-null   int64
 13  Tuberculosis                               6120 non-null   int64
 14  Cardiovascular Diseases                    6120 non-null   int64
 15  Lower Respiratory Infections               6120 non-null   int64
 16  Neonatal Disorders                         6120 non-null   int64
 17  Alcohol Use Disorders                      6120 non-null   int64
 18  Self-harm                                  6120 non-null   int64
 19  Exposure to Forces of Nature               6120 non-null   int64
 20  Diarrheal Diseases                         6120 non-null   int64
 21  Environmental Heat and Cold Exposure       6120 non-null   int64
 22  Neoplasms                                  6120 non-null   int64
 23  Conflict and Terrorism                     6120 non-null   int64
 24  Diabetes Mellitus                          6120 non-null   int64
 25  Chronic Kidney Disease                     6120 non-null   int64
 26  Poisonings                                 6120 non-null   int64
 27  Protein-Energy Malnutrition                6120 non-null   int64
 28  Road Injuries                              6120 non-null   int64
 29  Chronic Respiratory Diseases               6120 non-null   int64
 30  Cirrhosis and Other Chronic Liver Diseases 6120 non-null   int64
 31  Digestive Diseases                         6120 non-null   int64
 32  Fire, Heat, and Hot Substances             6120 non-null   int64
 33  Acute Hepatitis                            6120 non-null   int64
dtypes: int64(32), object(2)
memory usage: 1.6+ MB
```

Entendendo que as três primeiras colunas não participarão do cálculo de correlação, pois não geram valores significativos para a análise, criaremos uma nova lista a patir desta condição:

Criando a matriz numérica para o calculo da correlação.

```
[8] variaveis_numericas = causas_mortes.drop(columns= ['Country/Territory', 'Code', "Year"])
    variaveis_numericas.corr()
```

	Meningitis	Alzheimer's Disease and Other Dementias	Parkinson's Disease	Nutritional Deficiencies	Malaria	Drowning	Interpersonal Violence
Meningitis	1.000000	0.216713	0.351668	0.760851	0.755261	0.576347	0.447242
Alzheimer's Disease and Other Dementias	0.216713	1.000000	0.950785	0.193209	0.031290	0.599403	0.429622
Parkinson's Disease	0.351668	0.950785	1.000000	0.313033	0.084109	0.753663	0.485528
Nutritional Deficiencies	0.760851	0.193209	0.313033	1.000000	0.411149	0.596367	0.407065
Malaria	0.755261	0.031290	0.084109	0.411149	1.000000	0.195839	0.184469
Drowning	0.576347	0.599403	0.753663	0.596367	0.195839	1.000000	0.539339
Interpersonal Violence	0.447242	0.429622	0.485528	0.407065	0.184469	0.539339	1.000000

Agora, iremos importar a biblioteca sklearn.preprocessing e aplicaremos o método Standard Scaler para padroninzar as varáveis. Como a função StandardScaler() retorna um array, iremos criar uma nova variável para armazenar as colunas da lista "variaveis númericas"e, posteriormente, devolvê-las em forma de dataframe com os dados já padronizados. O método StandardScaler aplicará o procedimento de Z Score que se trata de um método para equalizar a escala dos dados. Consiste em selecionar cada registro, subtrair da média da variável e

dividir pelo desvio padrão da respectiva coluna. Tendo feito isso, teremos nossa tabela com os dados padronizados.

Padronizando as variáveis numéricas

```
[9]  from sklearn.preprocessing import StandardScaler
```

```
[32] colunas_numericas = variaveis_numericas.columns
     colunas_numericas
```

```
[33] padronizar = StandardScaler()
     variaveis_numericas = padronizar.fit_transform(variaveis_numericas)
     variaveis_numericas
```

```
     dados_padronizados = pd.DataFrame(variaveis_numericas, columns= colunas_numericas)
     dados_padronizados
```

Saída:

	Meningitis	Alzheimer's Disease and Other Dementias	Parkinson's Disease	Nutritional Deficiencies	Malaria	Drowning	Interpersonal Violence
0	0.057004	-0.173062	-0.145985	0.005270	-0.191593	-0.036522	-0.050031
1	-0.261658	-0.216862	-0.207291	-0.344914	-0.196091	-0.202428	-0.282897
2	-0.148138	-0.160258	-0.130989	-0.273852	-0.195656	-0.058634	-0.229172
3	-0.278119	-0.237545	-0.227579	-0.350893	-0.196091	-0.221827	-0.312668
4	-0.278274	-0.237371	-0.227359	-0.351234	-0.196091	-0.222369	-0.313010
...	...	...	...	...	...	...	...
199	-0.174849	-0.143341	-0.165612	-0.212015	-0.188788	-0.096075	0.172739
200	-0.089748	0.497955	0.429363	-0.099785	-0.174183	0.663863	-0.037712
201	-0.168637	-0.174800	-0.171345	-0.028040	-0.019910	-0.097974	-0.211720
202	0.430174	-0.221265	-0.208393	0.373732	0.203762	-0.157391	-0.235502
203	-0.102482	-0.211242	-0.200675	0.015349	-0.020635	-0.147488	-0.177329

204 rows × 31 columns

Com os dados padronizados, aplicaremos o método do PCA à matriz já balanceada.Importamos o método PCA da biblioteca sklearn.decomposition. Primeiramente, identificaremos todos os possíveis fatores que explicam os dados.

Aplicando o PCA para todos os possíveis fatores

```
[36] from sklearn.decomposition import PCA
```

```
n_fatores = dados_padronizados.shape[1]
n_fatores
```

```
31
```

```
[ ] pca = PCA(n_components= n_fatores)
    pca.fit(dados_padronizados)
```

```
PCA(n_components=31)
```

Agora, identificaremos os Autovalores, Autovetores e a Variância dos Fatores.

Checando os Autovalores, Autovetores e a Variância explicada pelos fatores

```
print("Auto-valores:")
print(pca.explained_variance_,'\n')

print("Auto-vetores:")
print(pca.components_,'\n')

print("Variância explicada:")
print(pca.explained_variance_ratio_,'\n')
```

Saída:

31 autovalores:

```
Auto-valores:
[1.99300611e+01 4.74314119e+00 1.22898295e+00 1.09824170e+00
 1.00989189e+00 8.29332013e-01 7.87385610e-01 5.04676150e-01
 3.17184379e-01 2.40795831e-01 1.40508114e-01 1.02866631e-01
 9.47869658e-02 2.78972100e-02 1.99389945e-02 1.83110228e-02
 1.29231371e-02 9.72009844e-03 7.72984349e-03 7.04018311e-03
 5.39136064e-03 4.21260567e-03 3.53495272e-03 2.60846074e-03
 1.88005946e-03 1.29350076e-03 9.82436491e-04 7.05879334e-04
 3.75837843e-04 1.99646016e-04 1.09623355e-04]
```

31 autovetores, cada um com 31 elementos:

```
Auto-vetores:
[[ 1.64461007e-01  1.55374077e-01  1.87791159e-01  1.81975191e-01
   7.38994117e-02  2.08991807e-01  1.64893359e-01  1.87456007e-01
   1.47464687e-01  1.12899741e-01  1.94307159e-01  1.94594677e-01
   2.10773825e-01  1.91457511e-01  1.70387251e-01  2.16127379e-01
   9.53307154e-02  1.81553618e-01  1.56611072e-01  1.69248378e-01
   1.00503425e-02  2.15336899e-01  2.16034816e-01  1.58309621e-01
   1.68703876e-01  1.98585985e-01  2.04568147e-01  2.18193507e-01
   2.21031542e-01  2.17714636e-01  1.87054867e-01]
 [-2.49462564e-01  2.85813742e-01  2.37920308e-01 -2.12549602e-01
  -2.15634606e-01  1.00001759e-01 -4.70192126e-03 -2.43500374e-01
  -2.25710792e-01  2.03856365e-01 -1.99568265e-01  2.19671840e-01
  -1.31284373e-01 -2.13431730e-01  1.63834801e-01  7.79670446e-02
  -3.74356311e-02 -2.54652134e-01  2.99555696e-02  2.87395688e-01
  -2.47342315e-02  3.63909470e-02  7.94913163e-02  2.52992438e-01
  -2.12195215e-01  1.78279485e-01  1.44199665e-01  2.09896776e-02
   2.58388626e-02 -3.74408850e-02 -2.00175250e-01]
```

Variância explicada pelos fatores:

```
Variância explicada:
[6.39753700e-01 1.52254532e-01 3.94502748e-02 3.52534892e-02
 3.24174659e-02 2.66215052e-02 2.52750283e-02 1.62000725e-02
 1.01815985e-02 7.72953096e-03 4.51030157e-03 3.30201236e-03
 3.04265561e-03 8.95498678e-04 6.40040463e-04 5.87782672e-04
 4.14831885e-04 3.12014545e-04 2.48127487e-04 2.25989433e-04
 1.73062336e-04 1.35224375e-04 1.13471759e-04 8.37314247e-05
 6.03497898e-05 4.15212926e-05 3.15361492e-05 2.26586820e-05
 1.20643710e-05 6.40862448e-06 3.51890275e-06]
```

Agora iremos plotar esses valores através da biblioteca plotly.express

```
import plotly.express as px
import numpy as np
```

```
fatores = [f'F{i+1}' for i in range(n_fatores)]
fatores
```

```
fig = px.bar (x= fatores, y= pca.explained_variance_ratio_, text= np.around(pca.explained_variance_ratio_, decimals= 2), title= 'Scree Plot' )
fig.update_layout(yaxis = { 'title': 'Porcentagem de variância explicada', 'tickfont' : { 'size' : 15}},
                  xaxis= {'title' : 'Fatores', 'tickfont' : {'size' : 15}},
                  title = {'font' : {'size' : 25}})
fig.show()
```

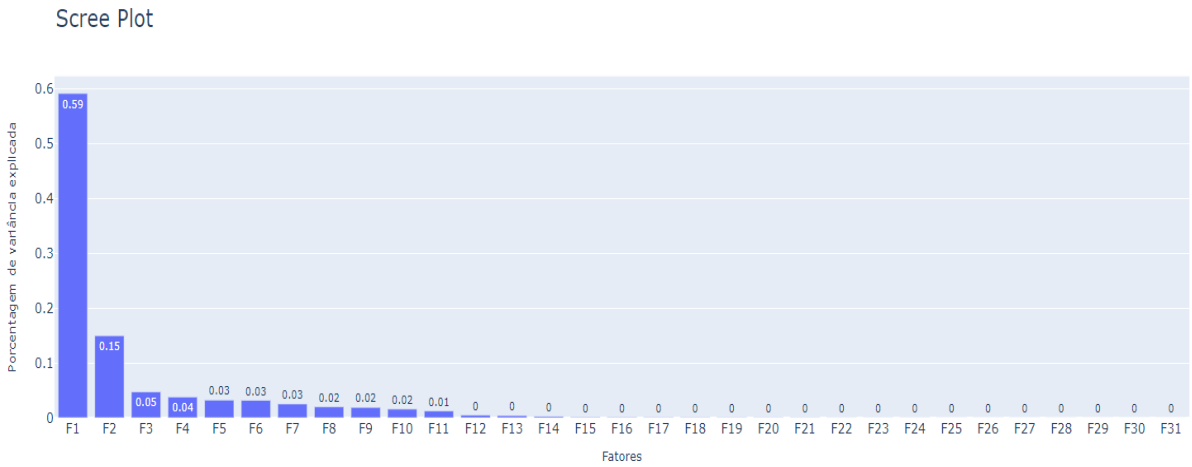

Podemos também analisar a variância acumulada entre os fatores:

```
variancia_acumulada = [sum(pca.explained_variance_ratio_[0:i+1]) for i in range(n_fatores)]
variancia_acumulada
```

```
[0.6397537000892095,
 0.7920082323249253,
 0.8314585071514891,
 0.8667119963309233,
 0.8991294621877256,
 0.9257509673534609,
 0.9510259956474102,
 0.9672260681424226,
 0.9774076666366699,
 0.985137197592408,
 0.9896474991659573,
 0.9929495115253922,
 0.9959921671313814,
 0.9968876658092681,
 0.9975277062718975,
 0.9981154889442506,
 0.9985303208288818,
 0.9988423353738827,
 0.9990904628611288,
 0.9993164522937183,
 0.999489514629319,
 0.9996247390047608,
 0.9997382107634321,
 0.9998219421881727,
 0.9998822919780096,
 0.999923813270599,
 0.9999553494198146,
 0.9999780081017727,
 0.999990072472769,
 0.9999964810972525,
 0.9999999999999993]
```

Por fim, iremos plotar os dois maiores fatores que explicam, juntos, aproximadamente 74% dos dados.

▾ Verificando os dois maiores Fatores

```
[ ]  pca = PCA(n_components= 2)
     pca.fit(dados_padronizados)

     PCA(n_components=2)
```

```
[ ]  fatores2 = [f'F{i+1}' for i in range(pca.n_components)]
     fatores2

     ['F1', 'F2']
```

```
[ ]  fig = px.bar (x= fatores2, y= pca.explained_variance_ratio_, text= np.around(pca.explained_variance_ratio_, decimals= 2), title= 'Scree Plot' )
     fig.update_layout(yaxis = { 'title': 'Porcentagem de variância explicada', 'tickfont' : { 'size' : 15}},
                       xaxis= {'title' : 'Fatores', 'tickfont' : {'size' : 15}},
                       title = {'font' : {'size' : 25}})
     fig.show()
```

Visualização do gráfico:

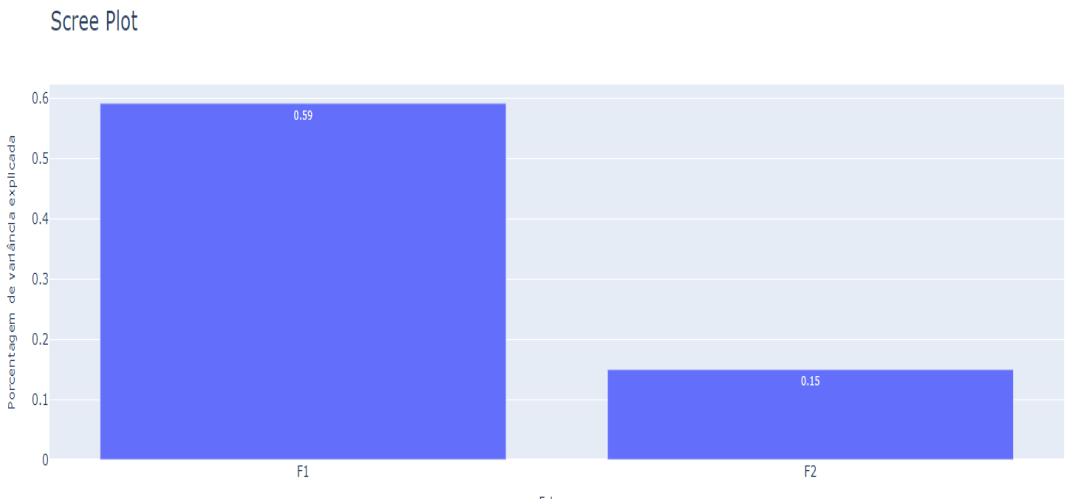

Link do repositório no Github: https://github.com/julianacamara98/Fatec